

# Weather and Climate Big Data

기상기후빅데이터

빅데이터 개론 3

오승민  
Spring 2025

# 빅데이터 개론 3

- 빅데이터 모델링
  - 분석 모형 설계
    - 분석 절차 수립
    - 분석 환경 구축
  - 분석기법 적용
    - 분석 기법
    - 고급 분석기법

# 분석 모형 설계

분석 절차 수립 > 분석 모형 선정

- **분석 모형 선정**

- 분석이 필요한 데이터 속성을 세부적으로 파악, 처리한 뒤에 분석 목적에 맞는 모형을 선정하고 적합한 분석 기법을 적용함.
- 빅데이터 분석은 전통적인 통계 분석 방식뿐 아니라, 기존 방식으로 는 분석이 어려웠던 데이터를 활용하여 의사결정, 불확실성 해소, 요약, 인과관계 파악, 예측 등을 수행함.
- 빅데이터 분석의 근본 목적은 과거의 데이터를 바탕으로 원인을 분석 하고, 이를 통해 미래를 예측하는 데 있음.
- 분석 모형 선정은 1) 문제 정의 또는 비즈니스 이해에 따른 데이터 선정 및 분석 목표 정의, 2) 데이터 수집 및 정리, 3) 데이터 전처리, 4) 분석 모형 선정의 순으로 진행

# 분석 모형 설계

분석 절차 수립 > 분석 모형 정의

- **분석 모형 정의**

- 분석 모형은 분석 목표에 따라 데이터 특성을 파악하고, 가설을 수립하여 전체적인 분석 방향을 정의하는 **구조적 틀**. 주요 분석 모형은 예측 분석 모형, 현황진단 모형, 최적화 분석 모형 등으로 구분 가능.
- **예측 분석 모형**: “어떤 일이 발생할까?” 과거와 현재의 데이터를 기반으로, 미래의 결과나 현상을 예측하는데 중점 (예: 수요예측, 매출예측, 기상 예보 등)
- **현황 진단 모형**: “왜 이런 일이 발생했는가?” 과거 데이터를 통해 현재의 문제 상황이나 이상 현상 원인을 분석, 진단 (예: 품질 문제 분석, 고객 이탈 원인 분석 등)
- **최적화 분석 모형**: “어떻게 하면 원하는 결과를 얻을 수 있을까?” 제한된 자원, 환경 내에서 최대의 효율, 이익을 내기 위한 의사결정 최적화에 중점 (예: 물류 경로 최적화, 재고관리, 마케팅 예산 분배 등)

# 분석 모형 설계

분석 절차 수립 > 분석 모형 정의

- **분석 모형 정의를 위한 사전 고려 사항**
  - **필요성:** 개인이나 조직 관점에서 분석 과제라 필요한지 판단
  - **파급효과:** 정성적, 정량적 기대효과의 정도 판단
  - **추진 시급성:** 당장 해소되어야 할 사회현안 여부 판단, 장기과제 성격 분리
  - **구현 가능성:** 과제를 구현함에 있어서 어려움이 없는지 현실성 판단
  - **데이터 수집 가능성:** 공공기관 협조나 데이터 확보, 데이터 구매 등 제약사항 판단
  - **모델 확장성:** 과제가 시범과제로 끝나지 않고 전체 데이터 모델로 확장 가능한지 판단
  - 추진 시급성과 구현 가능성만으로 사전 판별 기준 활용이 가능함.

# 분석 모형 설계

분석 절차 수립 > 분석 모형 구축 절차

- **분석 모형 구축 절차**

- **분석 시나리오 작성:** 분석의 전반적인 흐름을 이해하기 위한 단계. 분석 대상 및 범위를 요구사항에 맞게 정의하고, 해결하고자 하는 문제, 목표, 예측 결과, 활용 방안 등을 정리함. 또한, 분석과정에 필요한 데이터, 분석 절차, 분석 기법 등의 세부 사항을 구체적으로 설계.
- **분석 모형 설계:** 정의된 분석 목표에 따라 적합한 분석 방법론을 선정, 적절한 모형과 알고리즘을 선택. 이 과정에서 분석 모형의 개발 및 테스트 방안이 포함됨.
- **분석 모델링 검증:** 구축한 모형이 생성한 결과나 예측 성능이 통계적으로 유의미한지를 평가하는 단계. 모형의 신뢰성과 성능을 검증.

# 분석 모형 설계

분석 환경 구축 > 분석 도구 선정

- R 언어

- 1993년 오克兰드 대학교 통계학과 교수들이 통계분석과 자료의 시각화를 위해 개발한 오픈소스 분석용 프로그래밍 언어
- 객체지향 언어: 데이터가 객체 형태로 관리
- 고속메모리 처리: 모든 객체는 메모리로 로딩되어 처리 및 재사용
- 다양한 자료 구조: 벡터, 배열, 행렬, 데이터프레임, 리스트 등
- 최신 패키지 제공: 오픈소스 커뮤니티([www.r-project.org](http://www.r-project.org))를 통해 최신 방법론 제공
- 시각화: 데이터 분석과 표현을 위한 다양한 그래픽 도구 제공
- R Studio는 R을 위한 오픈소스 통합개발환경(IDE)

# 분석 모형 설계

분석 환경 구축 > 분석 도구 선정

- **파이썬(Python)**

- 1991년 프로그래머 귀도 반 로섬이 발표한 오픈소스 분석용 프로그래밍 언어
- 인터프리터 언어: 간결하고 쉬운 문법으로 컴파일, 실행, 테스트 용이
- 동적인 데이터 타입 결정 지원: 데이터 타입에 무관하게 모드 작성 가능
- 플랫폼 독립적: 운영체제에 독립적으로 컴파일 없이 동작 실행
- C언어를 포함한 다른 언어 프로그램들과 연동성이 높음
- 파이썬은 Anaconda를 통해 설치, 패키지 관리, 개발 환경 세팅까지 통합적으로 관리

# 분석 모형 설계

분석 환경 구축 > 분석 도구 선정

- **율리아(Julia)\***
  - 2012년 MIT에서 개발
  - 파이썬처럼 간결한 문법과 C/포트란 수준의 빠른 속도
  - 수치계산, 과학계산, 머신러닝, 시뮬레이션 분야에 특화
  - 아직 생태계가 작고, 튜토리얼, 오픈소스, 라이브러리 등이 부족
  - 또한, 기존 코드 및 시스템과의 호환성 문제로 일부 분야에서 사용 중
  - 유럽기상센터, 기후모델링 연구소, MIT, NASA 등에서 활용

# 분석 모형 설계

분석 환경 구축 > 데이터 분할

- 데이터 분할

- 정의: 분석용 데이터로 모형을 구축하여 평가 및 검증하기 위해 전체 데이터를 **학습 데이터, 평가 데이터, 검증용(테스트) 데이터**로 분할
- 학습 데이터: 모형을 학습시키기 위한 데이터로, 분석 모형을 실제로 만드는데 사용
- 평가 데이터: 추정한 분석 모형이 과대/과소적합인지 평가하기 위한 데이터
- 검증용 데이터: 최종적으로 학습된 모형이 새로운 데이터에도 잘 작동하는지 검증하는데 사용
- 보통 학습과 검증은 7:3 또는 8:2 비율로 분할, 훈련, 평가, 검증용은 4:3:3 또는 5:3:2로 분할

# 분석 모형 설계

분석 환경 구축 > 데이터 분할


- **과대적합(overfitting), 과소적합(underfitting)**
  - 과대적합(과적합): 학습데이터에 대해서는 높은 정확도를 나타내지만 테스트 데이터 (새로운 데이터)에 대한 성능이 낮은 것을 과대적합이라 함.
  - 과대적합 방지를 위해 데이터 분할 외에, K-fold 교차검증, 정규화 등의 방법이 있음.
  - 과소적합: 모형이 단순하여 데이터 내부의 패턴 또는 규칙을 잘 학습하지 못하는 경우. 학습 데이터에서도 정확한 결과를 도출하지 못함.
  - **일반화**: 학습된 모델이 검증용 테스트 데이터(새로운 데이터)에서도 높은 예측 성능을 유지하는 경우를 일반화된 모델이라 함.

# 분석 모형 설계



분석 환경 구축 > 데이터 분할

## Under- and Over-fitting

Regression:






predictor too inflexible:  
cannot capture pattern



predictor too flexible:  
fits noise in the data

Classification:



Copyright © 2014 Victor Lavrenko

출처: <https://www.youtube.com/watch?v=dBLZg-RqoLg>

# 빅데이터 개론 3

- 빅데이터 모델링
  - 분석 모형 설계
    - 분석 절차 수립
    - 분석 환경 구축
  - 분석기법 적용
    - 분석 기법
    - 고급 분석기법

# 분석 모형 설계

분석기법 적용 > 분석 기법

- 학습 유형에 따른 데이터 분석 모델
  - 지도학습(supervised learning): 정답(label)이 있는 데이터를 활용해 모델을 학습하는 방식
  - 비지도학습(unsupervised learning): 정답이 없는 데이터를 활용해 컴퓨터 스스로 숨겨진 패턴이나 구조를 학습하는 방식
  - 준지도학습(semi-supervised learning): 정답이 있는 데이터와 없는 데이터를 함께 활용하여 학습하는 방식
  - 강화학습(reinforcement learning): 주어진 환경에서 보상을 최대화하도록 에이전트가 스스로 학습하는 방식

# 분석 모형 설계

분석기법 적용 > 분석 기법

- 지도학습(supervised learning)
  - 분류(classification)와 회귀(regression)으로 구분 가능
  - **분류**: 주어진 데이터를 하나의 클래스(범주)로 분류. 대표기법: 의사결정 트리, 랜덤포레스트, 인공신경망, 서포트벡터머신, 로지스틱 회귀분석 등
  - **회귀**: 주어진 데이터의 특성을 기반으로 연속적인 값을 예측하는 것. 대표기법: 의사결정트리, 랜덤포레스트, 인공신경망, 선형회귀, 다중회귀 등
  - 지도학습은 입력 데이터와 레이블(정답)을 함께 제공하여 모델을 학습. 이때 사용되는 데이터셋이 훈련 데이터(training data)
  - 학습을 마친 후, 정답이 포함되지 않은 테스트 데이터셋(test data)을 이용해 모델 성능을 평가


# 분석 모형 설계

분석기법 적용 > 분석 기법

- 비지도학습(unsupervised learning)
  - 라벨이 없는 데이터에 대해, 데이터의 특성을 스스로 분석하여 어떤 특성의 그룹으로 구성되어 있는지 파악하는데 사용됨
  - 빅데이터 분석 프로젝트에서 초기 단계에서, 데이터가 동질적인 소규모 집단으로 구성되어 있는지 또는 이질적인 여러 집단으로 구성되어 있는지 탐색하는 데 활용 가능
  - 비지도 학습 방법: 군집분석(clustering), 연관성분석(association analysis), 인공신경망(neural networks), 오토인코더(auto-encoder) 등

# 분석 모형 설계

분석기법 적용 > 분석 기법



Examples of Supervised Learning (Linear Regression) and Unsupervised Learning (Clustering) 2.1.2  
Traditional Machine Learning.

# 분석 모형 설계


분석기법 적용 > 분석 기법

- **준지도학습(semi-supervised learning)**
  - 라벨이 없는 데이터에 소량의 라벨링된 데이터를 함께 사용하면, 라벨링 비용을 줄이면서도 상대적으로 높은 학습 정확도를 얻기 위한 학습 방식
  - 소수의 라벨된 데이터로 **초기 모델을 학습**한 후, 해당 모델을 이용해 나머지 라벨이 없는 데이터에 레이블을 부여(예측)하여, 전체 데이터를 대상으로 지도 학습을 수행함
  - 준지도 학습 기법: 셀프 트레이닝(Self-training) - 초기 모델이 예측한 라벨을 신뢰하고, 이를 새로운 학습 데이터로 활용하여 모델을 반복적으로 개선, GAN(Generative Adversarial Networks) 등
  - 라벨링 비용이 높은 분야(예: 의료 영상, 음성 데이터 등)에서 특히 유용하게 사용됨

# 분석 모형 설계

분석기법 적용 > 분석 기법

라벨이 있는 데이터  
(판별자의 분류/예측 훈련)



라벨이 없는 데이터  
(생성자가 만든 것 포함)

Photo by [TowardsDataScience](#)

# 분석 모형 설계

분석기법 적용 > 분석 기법


- **강화학습(reinforcement learning)**
  - 주어진 환경에서 보상을 최대화하도록 에이전트(agent)를 학습
  - 에이전트는 환경의 상태(state)를 입력받아 인공지능망 등을 통해 행동(action)을 결정함
  - 행동 결과로 보상 또는 벌칙(feedback)을 받으며, 이전 상태와 행동을 긍정적 또는 부정적으로 강화하며 학습 진행
  - 예시) 에이전트: 알파고, 환경: 바둑판, 규칙, 상대방 등, 상태: 현재 바둑판의 돌 배치 상황, 행동: 다음 수 선택, 보상: 이기면 +1점, 지면 -1점
  - 강화학습 기법: Q-러닝(Q-learning), 정책 경사법(Policy Gradient) 등

# 분석 모형 설계

분석기법 적용 > 분석 기법

- 회귀분석

- 특정 변수가 다른 변수에 어떤 영향을 미치는지를 수학적 모형으로 설명하고 예측하는 기법, 독립변수(입력값)와 종속변수(결과값)으로 구성됨
- 회귀선(회귀함수): 독립변수가 주어질 때의 종속변수의 기댓값
- 최소제곱법(최소자승법): 잔차 제곱의 합이 최소가 되도록 회귀선을 추정
- 모형진단: 적합도 검정(결정계수  $R^2$ ), 회귀계수의 통계적 유의성 검정 등



# 분석 모형 설계

분석기법 적용 > 분석 기법

- 선형회귀분석

- 종속변수(y)와 한 개 이상의 독립변수(X) 간 선형 관계를 파악하는 회귀 분석 기법. 종속변수는 연속형(수치형) 변수임.
- 단순 선형회귀분석: 하나의 종속변수와 하나의 독립변수 간의 관계 분석
- 다중 선형회귀분석: 하나의 종속변수와 여러 개의 독립변수 간의 관계 분석
- 일반화 선형모델(GLM: Generalised Linear Model): 선형회귀모형의 확장 형태로, 종속 변수가 정규분포 외의 분포(이항, 포아송 등)를 따를 때도 적용 가능한 모형. 예: 로지스틱 회귀, 포아송 회귀 등

# 분석 모형 설계


분석기법 적용 > 분석 기법

- 로지스틱 회귀분석(logistic regression)
  - 종속변수와 독립변수 간의 관계를 함수 형태로 예측하는 확률 기반 분류 모델. 종속변수가 범주형 변수일 때 사용됨.
  - 입력 데이터가 주어졌을 때, 특정 분류에 속할 확률을 예측하고 해당 확률을 바탕으로 결과 범주를 분류
  - 단순 로지스틱 회귀분석: 종속변수가 이항형 (예: 0 또는 1)
  - 다중 로지스틱 회귀분석: 종속변수가 3개 이상의 범주 (예: A, B, C)

# 분석 모형 설계


분석기법 적용 > 분석 기법

- 의사결정나무(Decision Tree)



# 분석 모형 설계

분석기법 적용 > 분석 기법



- 의사결정나무(Decision Tree)

- 의사결정 규칙을 나무(tree) 구조로 시각화하여, 전체 자료를 여러 개의 소집단으로 분류하거나 예측하는 기법
- 상위노드로부터 하위노드로 분기(split)되는 각 단계마다, 분류에 사용할 변수와 그 기준값을 어떻게 설정할지가 중요
- 모형의 크기(깊이)는 과대적합 또는 과소적합 되지 않도록 적절히 조절
- 분류나무: 목표 변수가 이산형(범주형)일 때 사용. 지니 지수(Gini index), 엔트로피 지수(Entropy index) 등을 기준으로 데이터의 불순도 (impurity)를 계산하여 분할
- 회귀나무: 목표변수가 연속형(수치형)일 때 사용. 각 노드 내의 평균과 분산 등을 기준으로 데이터 분할, 분산 감소 또는 F-통계량의 p-value 등을 활용하기도 함

# 분석 모형 설계


분석기법 적용 > 분석 기법

- **랜덤포레스트(Random Forest)**

- 부트스트래핑 기반 샘플링을 통해 여러 개의 의사결정나무(random forest)를 생성하고, 이를 배깅(bagging) 방식으로 앙상블하여 예측 성능을 높이는 학습 방법
- 부트스트래핑(bootstrapping): 복원추출방식(중복을 허용한 랜덤 샘플링)으로 원래 데이터와 크기가 동일한 여러 개의 표본 자료를 생성하는 방법
- 배깅(bagging: bootstrap aggregating): 여러 개의 부트스트랩 데이터셋을 각각 모델로 학습시키고, 여러 개의 분류기(또는 회귀기)를 결합하여 최종 예측을 수행하는 방법. 범주형 데이터는 다수결 투표 방식으로, 연속형 데이터는 평균으로 결과를 집계.
- 연속형/범주형 변수 모두 적용 가능하고 구조가 직관적이며 이해가 비교적 용이하지만, 트리구조가 복잡해지면 모델 해석력이 떨어짐.


# 분석 모형 설계

분석기법 적용 > 분석 기법



# 분석 모형 설계

분석기법 적용 > 분석 기법




- **인공신경망(ANN: Artificial Neural Network)**

- 인간의 신경세포(뉴런)가 연결된 구조를 모방한 기계학습 알고리즘. 하나의 뉴런이 다른 뉴런들과 연결되어 신호를 전달하고 처리하는 방식으로 동작.
- 입력데이터가 들어오면, 각 연결에서 가중치(weight)가 곱해지고, 이 값들의 선형 결합은 활성화 함수(activation function) (예: Relu, Sigmoid)를 통해 비선형 처리 되어 다음 층으로 전달.
- 출력값이 계산된 후, 예측값과 실제값의 차이(오차)를 줄이기 위해 가중치들이 반복적으로 조정 (back propagation 방식 등)
- 신경망 모형은 복잡성이 높고, 입력 변수 선택이나 전처리에 민감하게 반응할 수 있음.
- 범주형과 연속형 변수에 모두 적용 가능.

# 분석 모형 설계

분석기법 적용 > 분석 기법




- **인공신경망(ANN: Artificial Neural Network)**

- 과적합(Overfitting): 학습 데이터를 과하게 학습한 결과, 학습 데이터에 대해서는 높은 정확성을 보이지만, 새로운 데이터(테스트 데이터)에는 성능이 정하되는 현상
- 이를 해결하기 위해, 정규화(regularization), 드롭아웃(dropout), 하이퍼파라미터(hyperparameter) 최적화 등의 기법을 사용
- 기울기 소실(Vanishing gradient): 역전파를 통해 오차를 전달하는 과정에서, 깊은 신경망의 앞단으로 갈수록 기울기 값이 매우 작아져 가중치가 업데이트 되지 않는 현상
- 이를 해결하기 위해, Relu 활성화 함수를 사용 또는 LSTM, GRU와 같은 구조적 개선이 적용

# 분석 모형 설계

분석기법 적용 > 분석 기법

- **CNN(Convolutional Neural Network)**
  - 사람의 시신경 구조를 모방하여 만들어진 딥러닝 알고리즘으로 주로 이미지 처리와 시각적 패턴 인식에 특화되어 있음
  - 계층 구조: 합성곱 계층(convolutional layer)를 통한 국소적 특징 추출, 활성화 함수 계층(activation layer)를 통한 비선형성 부여, 풀링 계층(pooling layer)을 통한 특징 요약 및 연산량 감소, fully connected layer 통한 최종 분류 또는 예측
  - 대표적인 CNN 아키텍처로는 LeNet(1998), Alexnet(2012), GoogleLeNet(2014) 등이 있음.




# 분석 모형 설계

분석기법 적용 > 분석 기법

- **RNN(Recurrent Neural Network)**

- 순서를 갖는 데이터(예: 문장, 시계열 등)를 처리하기 적합한 딥러닝 모델
- 이전의 계산 결과(=과거 정보)를 기억하며 순차 데이터를 처리하는 순환 구조 딥러닝 알고리: 중간층(은닉층)이 반복적으로 연결되는 구조이며, 같은 가중치를 공유하며 순차적 관계를 학습
- 확률적 경사하강법(SGD)과 시간에 따른 역전파(BPTT) 등으로 학습



An unrolled recurrent neural network.


<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

# 분석 모형 설계

분석기법 적용 > 분석 기법

- **LSTM(Long Short-Term Memory Network)**

- RNN의 한 종류로, 일반 RNN의 한계(기울기 소실 문제 등)를 보완하기 위해 고안된 알고리즘
- 일반 RNN은 멀리 떨어진 과거정보를 학습하는데 어려움이 있음. 이를 해결하기 위해, LSTM은 셀 상태(cell state)라는 장기 메모리 저장 공간을 추가로 도입




# 분석 모형 설계

분석기법 적용 > 분석 기법

- **오토인코더(Auto-encoder)**

- 대표적인 비지도학습 신경망이며, 입력 -> 인코더 -> 은닉층 -> 디코더 -> 출력 구조.
- 입력과 출력의 차원은 동일, 중간 은닉층에서 차원 축소
- 출력이 입력과 최대한 유사하도록 가중치 학습
- 데이터 압축, 노이즈 제거, 이상치 탐지 등에 활용




<https://wikidocs.net/193827>

# 분석 모형 설계

분석기법 적용 > 분석 기법


- **GAN(Generative Adversarial Network)**
  - 생성자(generator)와 판별자(discriminator)로 구성된 딥러닝 모델
  - 생성자는 학습 데이터와 유사한 가짜 데이터를 생성, 판별자는 입력이 진짜인지 가짜인지 판별하는 역할을 하는데, 두 네트워크는 서로 경쟁하면서 동시에 학습
  - 지도학습(판별자)과 비지도학습(생성자) 딥러닝 모델의 결합된 형태



<https://wikidocs.net/192159>

# 분석 모형 설계

분석기법 적용 > 분석 기법



- **SVM (Support Vector Machine)**

- SVM은 지도학습 기법으로 고차원 공간에서 데이터를 나누는 초평면 (hyperplane)을 찾아 분류 또는 회귀를 수행
- 기존 분류기가 오류율 최소화를 목표로 하는데 반해, SVM은 클래스 간의 ‘여백(마진) 최대화’하는 초평면을 찾는 것을 목표로 함
- 분류와 회귀 모두 가능하며, 신경망보다 적은 양의 데이터로도 학습이 가능해 과대적합 가능성이 낮은 편
- 이진 분류에 특화되어 있으며, 데이터가 많거나 차원이 매우 클 경우 학습 시간이 오래 걸릴 수 있음

# 분석 모형 설계

분석기법 적용 > 분석 기법 (비지도학습)

- **연관성분석**

- 목표 변수가 없는 비지도 학습 기법으로 항목 간의 연관 규칙 (association rule)을 찾아내는 분석 방법 (예: 고객이 우유와 빵을 샀다면, 버터도 살 확률은?)
- 결과는  $A \Rightarrow B$ 로 표현되며, 지지도(support), 신뢰도(confidence), 향상도(lift) 등의 지표로 평가
- 콘텐츠 기반 추천 시스템의 기본 원리로 활용

# 분석 모형 설계

분석기법 적용 > 분석 기법 (비지도학습)

- **군집분석(clustering analysis)**

- 비지도 학습의 일종으로 주어진 개체들 간의 유사성을 기준으로 그룹(군집)을 자동으로 형성하는 분석 기법
- 유사성 판단은 보통 거리 기반 또는 유사도 기반 지표가 사용됨. 거리는 값이 작을 수록 두 개체가 유사, 유사도는 클수록 값이 유사함을 의미
- 계층적 군집분석: 상위-하위그룹 계층화된 구조로 군집을 형성
- 비계층적 군집분석: 사전에 군집수를 지정하고, 개체들을 해당 군집에 할당 (예: K-평균, 밀도기반 클러스터링, 확률분포 기반 클러스터링)
- 특정 변수에 대한 정의가 필요하지 않아 적용이 용이한 반면, 명확한 목표(정답 라벨링)가 없어 결과 해석이 어렵다는 단점

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- 범주형 자료 분석

- 이산형(범주형) 변수를 대상으로 한 분석 기법
- 분할표: 두 개 이상의 범주형 변수를 표 형태로 정리한 것
- 빈도 분석: 범주형 변수의 빈도와 비율을 계산하여 자료의 분포 파악
- 로지스틱 회귀분석: 종속변수가 범주형(예: 이진/다항 분류)일 때, 개별 관측치가 어느 집단에 속할 확률을 예측
- 교차분석 또는 카이제곱검정: 두 범주형 변수 간 독립성(상관성) 여부 판단
- t-검정: 두 범주(집단)의 평균 차이가 통계적으로 유의미한지 판단
- 분산 분석(ANOVA): 두 개 이상 집단 간 평균 차이를 비교

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- **다변량 분석**

- 하나의 조사 대상에 대한 두 개 이상의 변수(측정치)를 동시에 고려하여 변수 간 관계를 분석하는 모든 통계 기법
- 다중회귀분석: 하나의 종속변수와 하나 이상의 독립변수 간의 관계 분석
- 다변량분산분석(MANOVA), 다변량공분산분석(MANCOVA): 두 개 이상의 범주형 독립변수와 다수의 종속변수 간의 평균 차이 검정
- 정준상관분석: 다수의 수치형 독립변수와 종속변수 간의 관련성을 동시에 분석 (다중회귀분석의 확장으로 볼 수 있음)
- 요인분석(factor analysis): 많은 변수들 간의 상호관계를 바탕으로 공통된 잠재요인(factor)을 도출하는 분석 기법(변수 축소, 설문 문항 검증 등에 활용)

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- 시계열 분석
  - 시계열 자료를 분석하고 여러 변수들 간의 인과관계를 분석하는 방법

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- 베이즈 기법

- 베이즈 추론(Bayesian inference)은 통계적 추론의 한 방법으로, 사전 확률과 새로운 정보(데이터)를 결합해 사후 확률을 추론하는 방식
- 회귀에 적용: 선형회귀 등 회귀모델의 계수 추정을 정통적인 추정방식(최소제곱법 등)이 아닌, 베이즈 방식으로 수행
- 분류에 적용: 조건부 확률을 이용해 입력이 어느 범주에 속할 확률을 계산(나이브 베이즈 분류 등)

$$\underset{\substack{\text{사후 확률} \\ \text{(posterior)}}}{P(H|E)} = \frac{P(E|H) \overset{\substack{\text{사전 확률} \\ \text{(prior)}}}{P(H)}}{P(E)}$$

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- 비정형 데이터 분석

- 텍스트, 이미지, 음성, 동영상 등 구조화되지 않은 데이터를 대상으로 한 분석 기법
- 빅데이터 환경에서 80% 이상의 데이터가 비정형 데이터로 구성되었으나, 아직까지 정형데이터에 비해 분석 기법이 제한적
- 따라서, 정련과정을 통해 구조화(정형화)한 후, 기존 분석기법으로 정보를 발굴하는 방식이 일반적
- 데이터 마이닝(통계적 규칙이나 패턴을 분석하여 유의미한 정보를 추출), 텍스트 마이닝 (대규모 문서), 웹마이닝(인터넷에서 수집한 웹 로그, 검색 기록, 콘텐츠 등), 오피니언 마이닝(의견이나 리뷰 등), 리얼리티 마이닝 (스마트 센서에서 수집된 위치, 모션 등의 데이터) 등의 기법 적용

# 분석 모형 설계

분석기법 적용 > 고급 분석 기법

- 비모수 통계

- 모수는 어떤 시스템이나 함수의 특정한 성질을 나타내는 변수
- 비모수 통계는 모수에 대한 가정을 하지 않고 모집단의 형태에 관계없이 주어진 데이터에서 직접 확률을 계산하여 통계학적 검정을 수행
- 반면, 모수 통계는 데이터의 분포를 알거나 모수(평균이나 분산) 등을 안다고 가정하고 통계적 검정 및 추론을 수행
- 자료가 나타내는 모집단의 형상이 정규분포가 아닐 때, 표본이 적을 때, 명명척도 또는 서열척도 일 때 등의 경우에 비모수 통계 적용
- 윌콕슨 부호순위 검정, 만-위트니 U 검정, 프리드만 검정, 카이제곱 검정 등의 비모수 검정법이 있음