

Weather and Climate Big Data

기상기후빅데이터

빅데이터 개론 4

오승민
Spring 2025

빅데이터 개론 4

- 빅데이터 결과 해석
 - 분석 모형 평가 및 개선
 - ▶ 분석 모형 평가
 - ▶ 분석 모형 개선
 - 분석결과 해석 및 활용
 - ▶ 분석결과 해석
 - ▶ 분석결과 시각화
 - ▶ 분석결과 활용

분석 모형 평가 및 개선

분석 모형 평가 > 평가지표

- 지도학습-분류모델 평가 지표

- 오차행렬 (**Confusion Matrix**): 실제값과 예측값을 비교해 모델의 성능을 평가하는 표
- 정확도 (**Accuracy**): 전체 예측 중 정답 비율. 클래스 불균형이 클 경우 신뢰도 낮을 수 있음 $(TP+TN)/(TP+FP+TN+FN)$
- 정밀도 (**Precision**): 양성으로 예측한 것 중 실제 양성인 비율 $TP/(TP+FP)$
- 재현율 (**Recall**): 실제 양성 중에서 양성으로 정확히 예측한 비율 $TP/(TP+FN)$
- **F1-Score, ROC, AUC** 등: 다양한 관점에서 모델 성능을 종합적으로 평가할 수 있는 지표

	실제답	
	<i>Positive</i>	<i>Negative</i>
<i>Positive</i>	True Positive	False Positive
<i>Negative</i>	False Negative	True Negative

모델 예측

분석 모형 평가 및 개선

분석 모형 평가 > 평가지표

- 지도학습-회귀모델 평가 지표

- 실제값과 회귀 예측값의 차이를 기반으로 한 성능지표
- SSE(Sum Squared Error): 실제-예측값 차이 제곱 합
- MSE(Mean Squared Error): 실제-예측값 차이 제곱의 평균
- RMSE(Root Mean Squared Error): MSE에 루트를 취한 값
- MAE(Mean Absolute Error): 실제-예측값 차이 절대값 평균
- MPE(Mean Percentage Error): 실제 대비 예측 오차의 백분율 평균
- 결정계수 R^2 , Adjusted R^2 : 회귀모형의 설명력
- AIC(Akaike Information Criterion), BIC(Bayes Information Criteria): 모델의 복잡도와 성능을 함께 고려한 지표, 값이 작을 수록 좋음

분석 모형 평가 및 개선

분석 모형 평가 > 평가지표

- 비지도학습-군집분석 평가 지표

- 지도학습과 달리 실제 라벨이 없어 모델의 성능 평가가 어려움
- 내부 지표를 활용해 군집 간 분리도와 군집 내 응집도를 기반으로 평가
- 실루엣 계수(Silhouette Coefficient): 한 데이터가 자기 군집 내에서 얼마나 잘 어울리고, 다른 군집과는 얼마나 잘 분리돼 있는지를 측정
- 던 인덱스(Dunn index): 군집 간 최소 거리와 군집 내 요소 간 최대거리의 비율 (값이 클수록 군집 간 분리도는 크고 군집 내 응집도는 높다는 의미)

분석 모형 평가 및 개선

분석 모형 평가 > 평가지표

- **분석모형 진단 (모델이 통계적 가정을 잘 만족하고 있는가?)**
 - 최적의 회귀선은 실측치와 예측치의 차이인 잔차를 최소화하는 선. 잔차의 평균은 0이며, 정규분포를 따른다고 가정.
 - 정규성 가정: 통계적 검정이나 회귀분석 등에서, 데이터(또는 잔차)가 정규분포를 따른다는 가정을 확인하는 절차.

분석 모형 평가 및 개선

분석 모형 평가 > 평가지표


- **분석모형 진단 (모델이 통계적 가정을 잘 만족하고 있는가?)**
 - 최적의 회귀선은 실측치와 예측치의 차이인 잔차를 최소화하는 선. 잔차의 평균은 0이며, 정규분포를 따른다고 가정.
 - 정규성 가정: 통계적 검정이나 회귀분석 등에서, 데이터(또는 잔차)가 정규분포를 따른다는 가정을 확인하는 절차.
 - 잔차진단(모델이 통계적 가정을 만족하는지 확인)의 진단 포인트: 1) 잔차가 정규분포를 따르는지(정규성), 2) 패턴없이 고르게 퍼졌는지(등분산성), 3) 잔차 간 자기상관이 없는지(독립성)
 - 주요 방법: 샤피로-윌크 검정, 콜모고로프-스미르노프 검정(K-S test), Q-Q 플롯 등

분석 모형 평가 및 개선

분석 모형 평가 > 교차검증

- **k-폴드 교차검증(k-fold cross validation)**

- 전체 데이터셋을 k개의 서브셋으로 분리하여 그 중에 k-1개를 훈련 데이터로 사용하고 나머지 1개의 서브셋을 검증 데이터로 활용
- 이 과정을 k번 반복, 매 반복마다 검증 세트를 바꿔가며 모델 평가
- 모든 서브셋에 대한 평가 결과를 평균 내어 모델의 최종 성능 추정 (데이터 전체를 평가에 활용)



분석 모형 평가 및 개선

분석 모형 평가 > 모델 적합도

- **적합도 검정 (goodness of fit Test)**

- 관측된 데이터 분포가 가정한 분포 함수(정규분포, 이항분포 등)와 얼마나 유사한지를 평가
- 즉, 실제 데이터 분포와 이론적 분포 간의 차이를 검정하는 통계적 방법
- 정규성 검정: 데이터가 정규 분포를 따르는지 확인
- 카이제곱 검증: 이산형 데이터가 기대분포를 따르는지 확인
- 콜모고로프-스미르노프 검정: 연속형 데이터(실제 데이터)의 누적 분포와 특정 누적 분포 (가정한 분포) 함수 간의 차이 비교

분석 모형 평가 및 개선

분석 모형 개선 > 과적합 방지


- 과대적합 방지

- 훈련 시에는 높은 성능을 보이지만, 테스트 데이터에 대해 성능이 떨어지는 현상(과대적합)을 방지하고, 일반화된 모델을 생성하기 위해 다양한 기법을 활용
- 정규화(regularisation): 학습 중 큰 가중치(계수)에 패널티를 부여해 모델 복잡도를 줄임 (ridge, lasso)
- 드롭아웃(dropout): 신경망 훈련 시 일부 뉴런을 랜덤하게 비활성화
- 편향-분산 트레이드 오프(bias-variance trade-off): 모델이 너무 단순하면 높은 편향(과소적합), 반면에 모델이 너무 복잡하면 높은 분산(과적합), 따라서, 최적의 복잡도를 찾아 일반화 성능을 극대화하는 것이 목표

분석 모형 평가 및 개선

분석 모형 개선 > 매개변수 최적화

- 매개변수 최적화 (<-> 초매개변수: hyperparameter)
 - 신경망 학습의 목표는 손실함수(loss function)의 값을 최소화하는 매개변수(가중치와 편향)를 찾는 것. 이러한 최적값을 찾는 과정이 매개변수 최적화



분석 모형 평가 및 개선

분석 모형 개선 > 매개변수 최적화

- 매개변수 최적화 (<-> 초매개변수: hyperparameter)
 - 신경망 학습의 목표는 손실함수(loss function)의 값을 최소화하는 매개변수(가중치와 편향)를 찾는 것. 이러한 최적값을 찾는 과정이 매개변수 최적화
 - 확률적 경사 하강법(Stochastic Gradient Descent): 매개변수에 대한 손실함수의 기울기를 이용해, 매개변수를 반복적으로 업데이트
 - 모멘텀(Momentum): 확률적 경사 하강법에 속도 개념을 추가, 이전 업데이트 방향을 고려해, 빠르게 값이 수렴하도록 도와줌
 - AdaGrad(Adaptive Gradient): 학습률(매개변수를 얼마나 많이/적게 업데이트할지)를 조정하면서 학습 진행
 - Adam(Adaptive Moment Estimation): 모멘텀과 AdaGrad를 결합한 방법론.

분석 모형 평가 및 개선

분석 모형 개선 > 모형 융합

- **분석모형 융합**

- 앙상블 학습: 여러 개의 분석 예측 모형들을 만들고 결합하여, 최종적인 하나의 더 정확한 예측 모형을 만드는 방법
- 다양한 모델을 조합해 과적합을 줄이고 성능을 안정화
- 배깅(bagging): 데이터를 여러 번 샘플링(부트스트랩)해, 여러 모델을 학습 시킨 후, 평균 값 등을 취함
- 랜덤포레스트(random forest): 배깅 기반의 앙상블 기법. 여러 의사 결정트리를 학습시키되, 각 트리는 랜덤한 데이터셋과 변수로 구성.
- 부스팅(boosting): 모델을 순차적으로 학습. 이전 모델이 잘못 예측한 데이터에 가중치를 두어 다음 모델이 점점 보완하게끔 함

분석 모형 평가 및 개선

분석 모형 개선 > 최종모형 선정

- **최종모형 선정**

- 다양한 분석 모형 중에서 최종적으로 사용할 모형을 선정하기 위해, 모형 평가지표를 활용하여 성능을 비교
- 회귀모형에 대한 주요 성능평가 지표: SSE, R^2 , MAE, MAPE 등
- 분류모형에 대한 주요 성능평가 지표: 정확도, 정밀도, 재현율 등
- 비지도 학습 모형에 대한 주요 성능평가 지표: 군집 간 거리, 군집의 지름, 군집의 분산 등을 고려

빅데이터 개론 4

- 빅데이터 결과 해석
 - 분석 모형 평가 및 개선
 - 분석 모형 평가
 - 분석 모형 개선
 - 분석결과 해석 및 활용
 - 분석결과 해석
 - 분석결과 시각화
 - 분석결과 활용

분석 결과 해석 및 활용

분석 결과 해석



- **분석 모델 별 결과 해석**

- 모델 종류에 따라 해석 기준과 평가 지표가 상이
- 회귀모델: 잔차(실제값과 예측값의 차이)와 결정계수를 활용
- 분류모델: 클래스(양성/음성)에 대해 예측확률이 얼마나 정확한지 평가 (정확도, 정밀도, 재현율 등)
- 군집모델: 군집 별 통계량을 요약하여 각 그룹의 대표적 특성/패턴 파악, 그룹 내 관측치 간의 공통점과 변동성 파악.
- 비즈니스 기여도 평가: 데이터 분석 결과는 단순 모델 정확도 외에도 비즈니스 활용 가능성, 효율성 개선, 투자 수익률 (ROI)등으로 연결되어야 함

분석 결과 해석 및 활용

분석 결과 해석 > 모델 별 시각화

- 회귀모델 시각화






산점도(scatter)

분석 결과 해석 및 활용

분석 결과 해석 > 모델 별 시각화

평행좌표계



- 분류모델 시각화




분석 결과 해석 및 활용

분석 결과 해석 > 모델 별 시각화

- 딥러닝 모델 시각화



<https://playground.tensorflow.org/>




<https://poloclub.github.io/ganlab/>


분석 결과 해석 및 활용

분석 결과 해석 > 모델 별 시각화

- 군집분석 모델 시각화



- 연관분석 모델 시각화



분석 결과 해석 및 활용

분석 결과 시각화

- 데이터 시각화

- 분석된 결과를 해석하는 대표적인 방법으로, 데이터 값을 시각적 속성으로 변환하여 그래프, 차트 등의 형태로 표현
- 정보 전달을 명확하고 효과적으로 하기 위한 목적
- 데이터 유형(범주형과 수치형)에 따른 적절한 시각화 방식 선택이 중요

- 데이터 시각화 특성

- 데이터에 대한 즉각적인 해석과 판단이 가능
- 데이터의 특징, 패턴, 추세 등을 직관적으로 파악 가능
- 시간, 공간, 분포 등 다양한 측면에서의 표현이 가능
- 변수 간의 관계, 차이, 분포 등을 명확히 전달

분석 결과 해석 및 활용

분석 결과 시각화

- 데이터 시각화 영역


- 정보 시각화: 방대한 양의 정보를 한번에 이해할 수 있도록 직관적으로 표현하는 방법. 수치정보 뿐 아니라 비수치 정보(텍스트나 지형정보 등)까지 포함. 카토그램, 분기도, 개념도, 계통도, 네트워크 다이어그램, 트리맵 등 다양한 도구를 사용
- 인포그래픽: 복잡한 정보(수치, 텍스트 등)를 차트, 지도, 픽토그램, 일러스트레이션 등으로 한눈에 이해할 수 있게 만듦
- 정보 디자인: 정보를 구성하여 효율적으로 사용할 수 있게 하는 디자인 기술 및 업무. 데이터 시각화, 정보 시각화, 인포그래픽을 모두 포괄하는 개념

분석 결과 해석 및 활용


분석 결과 시각화

정보 시각화> 트리맵

에너지




산업공정



농업




폐기물



분석 결과 해석 및 활용


분석 결과 시각화

정보 시각화> 네트워크 다이어그램




분석 결과 해석 및 활용


분석 결과 시각화



정보 디자인(나폴레옹 진군맵)



정보 디자인(콜레라 발병맵)



비주



<https://www.tableau.com/ko-kr/learn/articles/best-beautiful-data-visualization-examples>

분석 결과 해석 및 활용

분석 결과 시각화

- 시간 시각화

- 시간에 따른 데이터의 변화를 표현하는 방법, 데이터의 경향성(트렌드) 또는 변동성 파악을 위해 사용
- 막대그래프, 누적막대그래프, 꺾은선 그래프, 계단 그래프, 추세선 등





분석 결과 해석 및 활용

분석 결과 시각화

• 분포 시각화


- 데이터의 분포를 시각적으로 표현하는 기법, 특정 변수의 값들이 어떻게 분포되어 있는지를 파악하기 위해 사용.
- 각 영역을 합치면 1 또는 100%가 되는 특징
- 히스토그램, 파이차트, 도넛차트, 누적연속그래프, 트리맵 등



분석 결과 해석 및 활용

분석 결과 시각화

- 관계 시각화
 - 데이터 사이의 관계를 시각적으로 표현
 - 산점도, 버블차트, 히트맵 등





분석 결과 해석 및 활용

분석 결과 시각화

- 비교 시각화

- 하나 이상의 변수에 대해서 변수 사이의 차이와 유사성 등을 표현하는 방법
- 히트맵, 체르노프 페이스, 스타차트, 평행좌표계, 다차원 척도법 등





분석 결과 해석 및 활용

분석 결과 시각화

- 공간 시각화

- 장소나 지역에 따른 데이터의 분포를 표현
- 단계구분도, 카토그램 등



분석 결과 해석 및 활용

분석 결과 활용

- 빅데이터 분석 방법론

- 빅데이터 분석을 위한 방법론은 데이터마이닝 방법론을 프로젝트 특성에 맞추어 적용
- CRISP-DM, SEMMA, KDD 및 국내 참조모델 등의 방법론 존재
- 한국데이터산업진흥원 참조모델은 데이터 분석 프로젝트를 위한 5단계를 정의: 분석기획 -> 데이터 준비 -> 데이터 분석 -> 시스템 구현 -> 평가 및 전개

*전개: 개발된 모델을 적용하여 결과를 확인하고 지속적인 관리를 위한 방법 제시

분석 결과 해석 및 활용

분석 결과 활용

- **분석결과 활용 계획 수립**

- 빅데이터 분석 결과를 어떻게 업무에 반영할 것인지에 대한 액션 플랜을 수립하고, 업무 성과를 지속적으로 모니터링 하기 위한 방안 마련
- 빅데이터 분석 모델을 성공적으로 도입했더라도, 분석 결과를 현업에서 적극 활용하고 지속적으로 모니터링하는 체계가 필요
- 빅데이터 분석 및 활용에 대한 이해 제고를 위해 내/외부 교육 훈련 방안을 수립
- 분석 모델의 지속적 활용 및 발전을 위해 기관 간 데이터 연계, 데이터 통합, 분석 결과의 활용 내용을 포함한 확산 계획을 고려하여 방안 수립

분석 결과 해석 및 활용

분석 결과 활용

- **분석결과 활용 시나리오 개발**

- 빅데이터 분석 과제를 계획할 때 활용 방안을 미리 고려해야 하며, 전개 단계에서는 계획단계에서 수립한 활용 방안을 시나리오 수준까지 구체화
- 과제 수행 후 분석 결과를 즉시 적용할 수 있는 단기 활용계획과 중장기 활용 계획 모두 필요

- **업무 적용 및 효과 검증**

- 빅데이터 분석 결과 활용 시 기대되는 성과를 조직 내에서 충분히 공유하여 빅데이터 활용에 대한 분위기를 조성
- 빅데이터 활용 효과를 지속적으로 검증, 활용효과 측정을 위한 성과 지표 마련 필요

분석 결과 해석 및 활용

분석 결과 활용

- **분석결과 적용과 보고서 작성**

- 실무자가 분석 결과를 업무에 어떻게 적용하였는지 확인하고 개선해야 할 사항이 있으면 분석 모델 리모델링에 반영
- 분석기획단계에서 설정된 기준에 따라 프로젝트의 성과를 정량적, 정성적으로 평가하고 프로젝트 성과 평가서를 작성

- **최종보고서 작성**

- 프로젝트 진행과정의 모든 산출물 및 프로세스를 정리하여 자산화하고 최종보고서를 작성하여 의사소통 절차에 따라 보고하고 프로젝트를 종료
- 프로젝트 개요, 수행 조직, 단계별 산출물 요약, 성과 평가 결과, 모니터링 및 개선 계획 등의 내용 포함

분석 결과 해석 및 활용

분석 결과 활용

- **분석모형 모니터링**

- 주변 환경과 데이터의 변화를 빅데이터 분석 모델에 지속적으로 반영하기 위해 분석 모형을 지속적으로 모니터링 하고 리모델링
- 모니터링 주요 대상: 분석 모델(알고리즘, 변수 등)과 데이터, 서비스 (활용방안 및 성과관리 등)
- 유지관리 주요 대상: 정책/제도, 업무, 관련 시스템, 인력 등

- **분석모형 리모델링**

- 새로운 데이터의 지속적인 유입, 정책이나 환경 등의 변화로 인해 분석 모델의 성능이 크게 감소할 수 있음
- 데이터의 수집, 전처리, 분석 방법론, 분석 결과까지 과제 전반에 대해 보완 또는 새롭게 추가할 사항을 정리 하여 개선 방안 도출